

Ejercicio 05 · Motor recomendador reproducible

INF-8239 Ciencia de Datos II · Unidad 03 · U03.E05 · Universidad Autónoma de Santo Domingo


Estudiante: Roberto Byas de la Cruz · Profesor: Edwin Ramón José Nolasco · Octubre 2026

Repositorio: https://github.com/RByas/INF8239_U03 — contiene src/, tests/, reports/, notebooks/ejercicio05.ipynb (ejecutado), requirements.txt, README y las tarjetas en docs/. MovieLens no se redistribuye: se descarga con scripts/download_data.py, que registra su SHA-256.

1. Datos y partición

MovieLens Latest Small (GroupLens; uso académico no comercial; Harper & Konstan, 2015, DOI 10.1145/2827872): 100,836 ratings de 610 usuarios sobre 9,742 películas (1996–2018), densidad 1.70 %, 18 películas sin ratings. Partición **temporal leave-one-out**: la última valoración de cada usuario va a prueba y el resto a entrenamiento, para no aprender del futuro. Se evalúan 587 usuarios; 23 se excluyen porque su película retenida no tiene ratings previos. Cobertura medida sobre los 9,701 ítems de entrenamiento.

Figura 1. MovieLens Latest Small: sesgo de rating y de popularidad



2. Tabla principal de resultados

Media de 3 semillas (42, 7, 123), 12 épocas. Popularidad media = ratings en entrenamiento de lo recomendado (alto = concentración en lo popular). Fuente: reports/lab09_summary.csv.


Estrategia	RMSE	HitRate@10	Cobertura	Popularidad media	Tiempo	Tamaño
Popularidad (no personalizada)	—	4.26 %	1.22 %	233 ratings	0 s	76 KB
Contenido (TF-IDF de géneros)	—	0.51 %	8.26 %	32 ratings	0 s	310 KB
Colaborativo, 20 factores	1.026	3.52 % ± 0.55	7.01 %	138 ratings	49 s	1.6 MB
Híbrido f=20, alpha 0.25	1.026	2.67 % ± 0.52	10.15 %	96 ratings	49 s	1.9 MB
Híbrido f=20, alpha 0.75	1.026	3.52 % ± 0.55	7.23 %	136 ratings	49 s	1.9 MB
Híbrido f=10, alpha 0.75	1.032	4.03 % ± 0.94	5.57 %	141 ratings	53 s	1.1 MB
Híbrido f=40, alpha 0.5 (seleccionado)	1.021	4.03 % ± 0.52	10.55 %	111 ratings	68 s	3.4 MB

Líneas base de rating sin factores latentes: media global RMSE 1.116; media de cada película RMSE 1.050. Precision@10 = HitRate@10 / 10 (un ítem relevante por usuario).

3. Baselines, errores e interpretación

Ratings: la factorización (RMSE 1.021–1.032) mejora solo 2–3 % sobre la media por película; más factores apenas reducen el error y no mejoran el ranking. **Ranking:** ninguna configuración personalizada supera a la popularidad en HitRate@10 (4.26 %); el mejor híbrido (4.03 %) queda dentro de la variación entre semillas (cada acierto vale 0.17 pp). El contenido solo casi no acierta (0.51 %) y produce empates masivos de similitud (362 para *Sabrina*). **Alpha:** en los tres tamaños, alpha 0.75 acierta 0.85–1.3 pp más que 0.25; alpha 0.25 cubre más catálogo. Alpha intercambia acierto por amplitud (Figura 2).

Figura 2. Efecto de alpha en el híbrido (media de 3 semillas)




4. Usuarios fríos

Un usuario nuevo recibe la lista de popularidad, idéntica en todas las semillas y declarada **no personalizada**. El usuario de historial amplio (2,697 ratings) obtiene listas sin ítems vistos y moderadamente estables (Jaccard 0.62 entre semillas). El de historial pequeño (19 ratings) obtiene listas totalmente inestables (Jaccard 0.00): sus factores son casi ruido. Las 18 películas sin ratings no pueden recomendarse en LAB09.

5. Decisión final (Pareto)

Utilidad = (HitRate@10, cobertura); costo = (tiempo, tamaño); ver Figura 3. La frontera deja 13 de 14 configuraciones no dominadas porque el tiempo de entrenamiento tiene ruido de carga de la máquina, así que la elección depende del peso de la cobertura. **Seleccionado: híbrido con 40 factores y alpha 0.5**: iguala el mejor HitRate híbrido, duplica la cobertura del f=10 alpha 0.75 (10.55 % frente a 5.57 %), concentra menos lo popular y domina al f=40 alpha 0.75. Alternativa Green AI: f=10 alpha 0.75 (un tercio del tamaño). Fallback de popularidad para usuarios nuevos y con poco historial.

Figura 3. Aciertos frente a cobertura (media ± desviación de 3 semillas)



6. Límites y riesgos

Popularidad dominante y burbuja de filtro; sesgo de selección (solo se observa lo consumido); sin demografía, no puede evaluarse equidad por grupos; retroalimentación entre recomendaciones y datos futuros; factorización sin sesgos de usuario/ítem; dataset de desarrollo y población no representativa. Detalle en docs/SYSTEM_CARD.md.

7. Uso de IA

Se usó Claude (Anthropic, modelo Claude Opus 5.5) para revisar el proyecto contra el manual y el enunciado, corregir errores, ampliar la evaluación de LAB09, escribir tests, el notebook y las tarjetas, y redactar borradores. Se verificó con 17 tests, ruff, la reproducción exacta de las métricas originales y la coincidencia del notebook con los reportes. Correcciones relevantes: conteo de ratings erróneo en LAB08, criterio de Pareto y eliminación de un módulo innecesario. La declaración completa (prompts, verificaciones y correcciones) está en el README.

8. Reproducción

```
uv sync · uv run pytest -q · uv run python scripts/download_data.py · uv run python
scripts/lab08_content.py · uv run python scripts/lab09_experiments.py · uv run jupyter nbconvert --to
notebook --execute --inplace notebooks/ejercicio05.ipynb
```